

# HW4 信息检索系统功能设计

## 1. 背景与意义

### 1.1 数据技术时代的到来

随着云计算、互联网技术的迅猛发展，人类已经进入了数据技术时代，为充分发现数据的潜在价值，更需要重视对数据挖掘技术的研究。在数据技术时代，信息量呈现爆炸式的增长，从而使得客户想要找寻所需要的信息变得越来越难。虽然搜索引擎可以在一定程度上帮助用户过滤信息，但是，现有的搜索引擎难以满足客户快速找寻满意商品的需求，客户想要找寻心仪的商品，往往需要浏览多个电商网站进行分析比较。

推荐系统旨在帮助用户从纷繁复杂的数据中提取出感兴趣的信息，在提高效率的同时，也有助于提升用户满意度与平台效益。近十年来推荐系统技术得到了长足发展，不仅成为学术界的研究热点之一，也已经成功地运用在电商、新闻和音乐推荐等多个场景中。其中，**会话推荐**（包括基于会话的推荐与会话感知推荐，但不包括普通序列推荐）旨在以用户当前的项目交互序列为主，以历史会话数据、场景、知识图谱等信息为辅，重在通过各种方式捕捉用户的当前兴趣。


### 1.2 消费者的个性化需求

目前，个性化推荐系统研究的重点已经由扩展新客户阶段逐步转向存量用户经营阶段，对客户进行精准推荐，则是现有推荐技术研究的主要方向之一。

个性化购物推荐系统应充分结合客户的偏好特征，在合适的时间为其推荐满足其喜好的物品。一个性能优越的电商网站要综合考虑多方面的因素。例如，Amazon网站会通过对客户访问某站点时间、频次的分析，实时更新物品推荐列表。好的推荐算法能够帮助用户快速定位目标，节约大量时间，提升用户体验。同时，它能帮助商家实现精准营销，从而提高交易量，使利润增长。

## 2. 现状分析

个性化推荐系统在现在的网络平台（或应用）中已经得到了广泛的应用，已解决它们面对的信息过载的问题。大多数推荐模型都是基于单一行为（称为单一行为推荐模型）设计的，即用户和项目之间的一种关联。例如，如下图a所示，在构建推荐模型时只使用购买行为。然而在真实场景中，用户行为通常不止一种。例如，如下图b所示，除了购买行为外，单击并添加到购物车也可以在一定程度上反映用户的偏好。我们通常将购买行为视为**目标行为**，其他类型的行为视为**辅助行为**。近年来，越来越多的研究发现，仅仅利用购买行为是远远不够的，而辅助行为在帮助预测目标行为方面具有巨大的潜力。



为了充分利用这些不同类型的行为，近年来出现了一些**多行为推荐模型**。一种简单的方法是直接建模所有类型的行为，并应用单一行为推荐模型，而不考虑行为之间的差异。为了区分不同行为的语义，一些工作将不同的可学习权重分配给不同的边缘，以建模行为的重要性。此外，最近的一些研究为每个行为提供了一种嵌入表示，它可以配合节点嵌入来参与图卷积运算。

尽管取得了成功，但这些模型仍面临以下缺点。首先，他们主要关注有效融合多种行为，并捕捉这些行为的差异。然而，他们大多忽略了利用这些行为的**共性**，这对推荐性能也非常重要。这些共性可以反映用户在不同行为中的总体偏好，这些偏好通常对用户是否进行目标行为（例如购买）起决定性作用。因此，我们需要挖掘目标行为与其他行为之间的共性，并将这些共性整合到目标行为中，以提高目标行为下嵌入的质量，从而达到更高精度的推荐效果。

其次，大多数方法都没有考虑用户独立个体的历史行为，若假定用户是匿名的，这会导致非个性化的推荐。这些方法主要依靠当前会话的项目信息形成会话表示，然后利用项目相关性进行推荐，而忽略了用户特征和历史行为的影响。如下图，给定用户AB，他们有类似的会话序列，*Iphone* → *Phone case* → *AirPods*。先前的方法通常对不同的用户产生相同的候选项目。但是用户有可能已经登陆，或存在某种形式的用户标识符。在这种情况下，可以合理地假设**历史会话中的用户行为**在提供个性化建议时是有用的。



除此之外，**数据稀疏**也是一个问题。大多数推荐模型都是基于监督范式的，用户和项目之间观察到的目标行为通常被视为监督信号。然而，稀疏监督信号不能保证图形学习的质量。为了解决这一问题，人们在单行为推荐方面做了一些努力，将单行为图分成两个视图进行对比学习。然而，这些方法不能直接应用于多行为推荐，因为它们忽略了辅助行为对目标行为的影响，放弃了它们的协同作用。因此，在多行为推荐领域，开发一种新的方案来解决这一问题显得尤为重要。

## 3. 方案设计

### 3.1 设计需求

#### 3.1.1 技术可行性

本推荐系统以给定的历史信息 and 当前会话作为输入，构建一个全局异构图，该图由用户节点和项目节点组成；利用历史交互构造用户项边，获得长期偏好，并且采用成对项目转换来构建项目之间的连接。为了获取潜在相关性，使用全局共现信息计算相似项构建边。在此基础上，使用异构图神经网络(HGNN)来学习具有丰富语义的长期用户偏好和项目表示。此外，使用个性化会话编码器将当前会话的项目信息和一般用户偏好相结合。

为了利用辅助行为，采取多行为推荐模型，自动学习权重来聚合多个行为下的嵌入。为了缓解数据稀疏问题，采取星形对比学习任务。最后采取梯度手术来解决多任务下的梯度冲突问题，完成整体优化。

这些技术在实验环境下经验证，证明有相对较好的性能。因此技术上具有可行性。

#### 3.1.2 经济可行性

此购物推荐系统正是考虑为用户提高购物效率，节省手动筛选对比时间，更加深入了解用户的购物欲望，实现精准偏好推荐，增加收益。而且此购物推荐系统的数据库方便管理人员操作与管理，因此本系统的开发在经济上是完全可行的。开发此系统需要大量的历史数据，需要一定的研发成本，但对于需要精准定位客户偏好的大企业来说可以承担其初期开发费用。

此推荐系统开发完成后可持续投入使用，并由精准推荐偏好产品而提高交易量，产生的收入能够覆盖项目开发成本及今后的运行、维护费用。估计收益将高于开发成本，因此经济上可行。

### 3.1.3 操作可行性

由于科技的飞速发展，计算机与手机早普及世界的方方面面，使人们对工作效率和可操作性都有了更高的要求。因此，智能推荐系统是信息检索发展的必然趋势，提高工作效率，降低时间成本。用户只需要开始一段会话系统便自动运行，进行偏好推荐，对于用户来说具有操作简单，无需经过复杂的培训和学习。而对于管理人员来说，只需定期维护数据即可。因此此推荐系统具有操作可行性。

## 3.2 产品功能

此产品的功能为：给定用户购买记录的历史信息，利用用户的当前会话，预测短期互动会话的下一次互动。

此推荐系统有以下特点：

- 除了利用用户的主要购买行为之外，还能利用辅助行为帮助预测目标。
- 利用全局共现项目发掘用户在不同行为中的总体偏好，并将这些共性整合到目标行为中，从而达到更精确的推荐。
- 使用个性化会话编码器将当前偏好与长期偏好相结合。
- 采取星形对比学习任务，缓解数据稀疏问题。
- 使用梯度手术，解决多任务下的梯度冲突问题。

## 4. 技术路线

### 4.1 全局异构图的构建

**项到项：**项目之间的转换关系可以包括会话中相邻的交互行为和同一会话之间频繁的共现行为，这两种行为是相辅相成的。在会话中定义 $v_i$ 到 $v_j$ 的两条边 $(v_i, v_j, r_{in})$ 和 $(v_i, v_j, r_{out})$ ，同时，对于每个节点，生成它的边的权重，对于每条边，利用它在所有历史会话中的频率作为边缘权重。为了确保项目的相关性，只对图G中节点 $v_i$ 的S个权重最大的边抽样。

此外，采用共现(co-occurrence)信息来构造项目之间的边。两个项目在不同会话中的频繁共现行为可以显示出较强的项目相关性。对于项目 $v_i$ ，我们基于所有的历史会话计算它的共现项，去共现次数最大的前k个。因此，定义两个共现项 $v_i$ 和 $v_j$ 的边为 $(v_i, v_j, r_{similar})$ ， $v_i$ 和 $v_j$ 共现的频次可以计算为

$$f_v(v_i, v_j) = \frac{\sum_{s \in N(v_i) \cap N(v_j)} \frac{1}{|N(s)|}}{\sqrt{|N(v_i)| |N(v_j)|}},$$

避免引入过多噪声，使用 $v_i$ 的前K个相邻节点，因此，对于节点 $v_i$ ，只有 $K'_{v_i}$ 可以被构建为 $r_{similar}$

$$K'_{v_i} = \min\{K, |N_{v_i}|\},$$

$$N_{v_i} = \{v_j | (v_i, v_j, r) \text{ where } r \in \{r_{in}, r_{out}\}\}.$$

**项到用户：**项目到用户元路径直接表示用户与项目之间的交互行为，揭示了用户隐含的长期偏好。将项目与用户之间的交互转换为图中两种类型的有向边： $(u_j, u_i, r_{interact})$ 和 $(u_i, u_j, r_{interactedby})$ ，定义为用户 $u_i$ 和用户 $u_j$ 之间有交互。

综上所述，构造了一个新的具有两种节点的异构全局图G，此全局图包含会话中的基本成对项转换、用户项历史交互和全局共现信息。利用全局图统一用户和项表示的学习，并捕获项目相关性和长期用户偏好。

## 4.2 异构全局图神经网络HGNN

在有向异构全局图上提出了一种异构图神经网络HGNN来编码用户和项目的表示。项ID  $q_{u_i}^{(0)}$  和用户ID  $p_{v_j}^{(0)}$  在模型中被嵌入到d维向量空间中作为初始节点特征。在GNN层中，存在三种连接项目邻居的边， $r_{in}, r_{out}, r_{similar}$ ，有一种连接用户邻居的边类型  $r_{interactedby}$ 。对于每种边类型，收集所有邻居信息  $N_{r_x}^{(v_j)}$ ，聚合过程为：

$$\mathbf{p}_{N_{r_x}(v_i)}^{(k+1)} = \frac{1}{|N_{r_x}(v_i)|} \sum_{n \in N_{r_x}(v_i)} \mathbf{e}_n^{(k)},$$

$$\mathbf{p}_{v_i, r_x}^{(k+1)} = f(\mathbf{W}_{r_x}^{(k+1)} [\mathbf{p}_{N_{r_x}(v_i)}^{(k+1)} || \mathbf{p}_{v_i}^{(k)}] + \mathbf{b}_{r_x}^{(k+1)}),$$

对于每个项目  $v_i$ ，聚合不同类型的边传播的不同信息，并更新项节点表示

$$\mathbf{p}_{v_i}^{(k+1)} = \text{accum}(\mathbf{p}_{v_i, r_u}^{(k+1)}, \mathbf{p}_{v_i, r_{in}}^{(k+1)}, \mathbf{p}_{v_i, r_{out}}^{(k+1)}, \mathbf{p}_{v_i, r_{similar}}^{(k+1)}),$$

更新后的用户节点表示为

$$\mathbf{q}_{u_i}^{(k+1)} = \text{accum}(\mathbf{q}_{u_i, r_v}^{(k+1)}),$$

K层HGNN后，我们将每个层中的嵌入进行组合，形成用户和项目的最终全局表示

$$\mathbf{q}_{u_i} = \sum_{k=0}^K \alpha_k \mathbf{q}_{u_i}^{(k)}; \quad \mathbf{p}_{v_i} = \sum_{k=0}^K \alpha_k \mathbf{p}_{v_i}^{(k)},$$

通过HGNN，可以了解长期的用户偏好和全局级别的项目嵌入。

## 4.3 个性化会话编码器

基于当前会话的用户偏好建模需要考虑用户的偏移偏好和一般偏好。偏移偏好是动态的，可以从当前会话中学习。

用户的下一次交互行为是灵活的，并且会受到长期稳定的用户偏好的影响。因此，使用一个**基于注意机制**的一般偏好学习模块来捕获一般偏好。

### 4.3.1 当前偏移偏好

为了捕获当前会话中用户的主要目的并将当前会话表示为嵌入向量，采用了一种项目级注意机制，动态选择并线性组合不同点项目当前会话信息。每个项目对会话的贡献往往收到项目位置信息（即会话序列的时间顺序）的影响。基本思想为使用给定当前会话的最后  $l$  个项目，连接由HGNN得到的反向位置表示  $p_{v_i}$  和反向位置信息：

$$\mathbf{p}_{v_i^s}' = \mathbf{W}_c [\mathbf{p}_{v_i^s} || \mathbf{l}_i],$$

基本会话表示为会话的项目表示的平均值：

$$\mathbf{p}_s' = \frac{1}{l} \sum_{i=1}^l \mathbf{p}_{v_i^s}',$$

用软注意机制来学习会话中每个项目的相应权重：

$$\alpha_i = \text{softmax}_i(\epsilon_i),$$

$$\epsilon_i = \mathbf{v}_0^T \sigma(\mathbf{W}_0 \mathbf{p}'_{v_i^s} + \mathbf{W}_1 \mathbf{p}'_s + \mathbf{b}_0),$$

给定session的当前表示 $\mathbf{C}_u$ 被定义为:

$$\mathbf{C}_u = \sum_{i=1}^l \alpha_i \mathbf{p}'_{v_i^s}.$$

### 4.3.2 一般偏好学习

由HGNN层学习到的用户嵌入 $\mathbf{q}_u$ 包含用户u的长期稳定的偏好，考虑当前会话中项目与用户总体偏好之间的相关性，并通过注意机制学习相应的权重。之后线性组合项目表示，获得当前会话的一般偏好。

在构建集成表示时，这两种不同类型的偏好表示可能有不同的贡献。一般会话偏好 $\mathbf{O}_u$ 考虑了用户长期偏好的影响，而当前偏好表示 $\mathbf{C}_u$ 包含当前会话的基本项目信息。最终的会话偏好表示 $\mathbf{S}_u$ :

$$\alpha_c = \sigma(\mathbf{W}_s[\mathbf{C}_u || \mathbf{O}_u]),$$

$$\mathbf{S}_u = \alpha_c \cdot \mathbf{C}_u + (1 - \alpha_c) \cdot \mathbf{O}_u,$$

## 4.4 星形的自监督任务

为了捕捉目标和辅助行为之间的关系，使用星形对比结构，即只需要在目标和每个辅助行为子图之间进行对比学习。通过这种方式，我们可以捕捉这些多种行为的共性，并使用它们来增强嵌入在目标行为下的表示能力。

使用GCNs获得了每个子图下的用户和项的嵌入。对比学习的一个非常重要的步骤是选择合理的正面和负面例子。大多数实践是，正对强调同一节点的不同视图之间的一致性，而负对强调不同节点之间的差异。然而，在目标行为下具有类似关联信息的用户（或项目）也应被视为积极的例子。因此，引入点态互信息 (PMI) 来计算目标行为下两个用户（或项目）之间的相似性。

在找到正例和负例后，采用对比损失，即 InfoNCE，来最大化正例对的一致性，最小化负例对的一致性。

## 4.5 梯度手术

多任务学习中不同任务之间可能存在梯度冲突。不同任务的梯度方向夹角大于90度，不利于模型的表现。

$$\mathbf{g}_i = \mathbf{g}_i - \frac{(\mathbf{g}_j \cdot \mathbf{g}_i)}{\|\mathbf{g}_j\|^2} \cdot \mathbf{g}_j.$$

梯度手术就是将第i个任务的梯度 $\mathbf{g}_i$ 投影到另一个冲突任务的梯度 $\mathbf{g}_j$ 的法线上，这个方法在一定程度上是有效的，但需要在主任务和辅助任务之间进行平衡，因此要对主任务进行梯度修饰。首先合并辅助任务的梯度，然后使用系数 $\lambda$ 来调整它们。

$$\mathbf{g}_{aux} = \lambda(\mathbf{g}_1 + \mathbf{g}_2 + \dots)$$

然后再主任务和合并的辅助任务的梯度之间应用梯度手术，最终得到梯度 $\mathbf{g}$ 。

至此，推荐系统的整体优化完成。

## 5. 总结



本购物推荐系统旨在辅助消费者进行商品的选购，节省浏览时间，实现更加精确的推荐。因此采用了一系列新技术来实现预测，包括全局异构图神经网络HGNN、个性化会话编码器、星形的自监督任务、梯度手术等，并利用了当前会话信息、历史会话信息以及辅助行为等信息。这些技术在实验环境下的各个评价指标（如Recall、HR、MRR）下都有良好的表现，预计在实际应用环境中也能获得良好的性能，能够带来巨大的收益。

## 6. 参考文献

---

1. 朱志国,李伟玥,姜盼,周沛瑶.图神经网络会话推荐系统综述[J/OL].计算机工程与应用:1-17[2022-11-26].<http://kns.cnki.net/kcms/detail/11.2127.tp.20221102.1732.011.html>
2. 吴静,谢辉,姜火文.图神经网络推荐系统综述[J].计算机科学与探索,2022,16(10):2249-2263.
3. 张文博. 个性化购物推荐系统的研究与实现[D].山东大学,2021.DOI:10.27272/d.cnki.gshdu.2021.006783.
4. 朱育颀,刘虎沉.网上购物平台多推荐融合算法研究[J].计算机科学,2021,48(S2):232-235.
5. Gu, Shuyun et al. "Self-supervised Graph Neural Networks for Multi-behavior Recommendation." *IJCAI* (2022).
6. Pang, Yitong et al. "Heterogeneous Global Graph Neural Networks for Personalized Session-based Recommendation." *Proceedings of the Fifteenth ACM International Conference on Web Search and Data Mining* (2022): n. pag.
7. Bi, Qiwei et al. "MTRec: Multi-Task Learning over BERT for News Recommendation." *FINDINGS* (2022).